

דוח פרוייקט - נושאים באנליזה של מידע

מגשים
דור לבל נדב שקד
312494925 205872807

הערה:

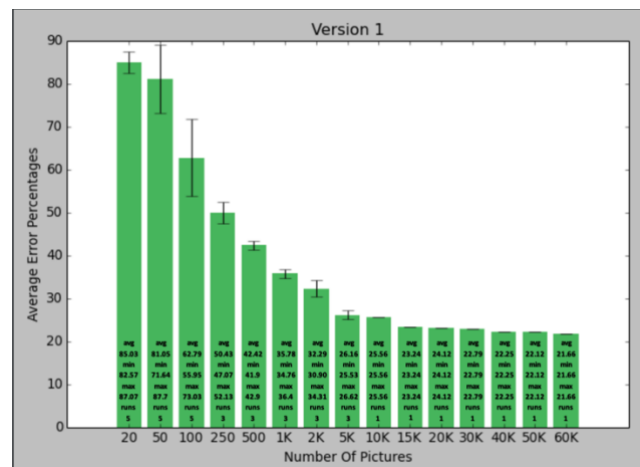
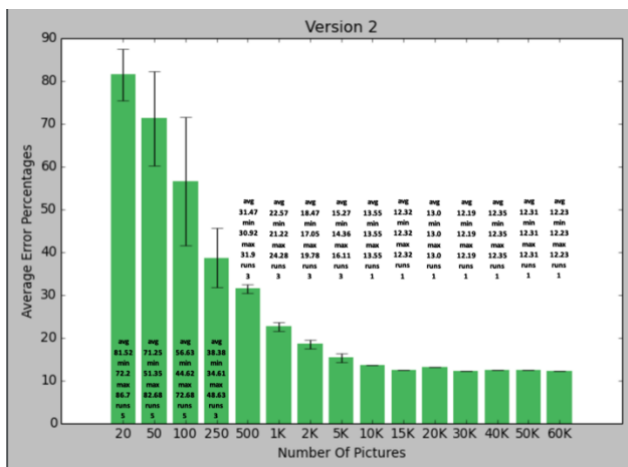
כל הרצות האלגוריתם בדוח זה נעשו עם הפרמטרים $P=10$ ו $L=7$, כל עוד לא צוין אחרת.
כל ה confusion matrix נבנו על מדגם אימון של 60000 תמונות ומדגם בדיקה של 10000 תמונות.

1. קבוצת התנאים בגרסה השנייה של המימוש:
 - בעזרת פונקציית העזר "sumCube" שכתבנו, ניתן לבחור מרובע (המורכב מפיקסלים) בגודל לבחירתנו (שולחים לפונקציה את מספר השורות והעמודות הרצוי, יחד עם נקודת ההתחלה). הפונקציה סוכמת את ערכי הפיקסלים של המרובע הנבחר, את הערך המתקבל אנחנו משווים לערך מסוים והפרדיקט יחזיר תשובה בהתאם להשוואה.
לאחר בדיקות רבות הסקנו שהקבוצות היעילות ביותר הן:
 - קבוצת הפרדיקטים הבודקים אם סכום הפיקסלים במרובע 3×3 גדול מ-300.
 - קבוצת הפרדיקטים הבודקים אם סכום הפיקסלים במרובע 2×14 גדול מ-600.
 - בעזרת תנאים אלו, כלומר - בעזרת בדיקה של קבוצת פיקסלים, שיפרנו את היכולת להסיק מהי הצורה הכללית של האיבר אותו דגמנו. זאת לעומת האלטרנטיבה - לפיה למדנו על הצורה על ידי בדיקה של פיקסלים בודדים.
 - תנאי נוסף בו השתמשנו הוא: קבוצת פרדיקטים, הבודקת עבור כל שורה וכל טור את מספר הפעמים בהם ערך של פיקסל באותה שורה (או טור) משתנה מאפס לערך חיובי, או להפך (כלומר מתאפס). בעזרת בדיקה זו, ניתן לזהות בצורה מדויקת יותר "אזורים ריקים" בתמונה - כלומר פיקסלים שאינם חלק מהצורה הכללית של האיבר אותו אנו דוגמים - ובכך להסיק טוב יותר איזו ספרה נדגמה.
בעזרת קבוצות פרדיקטים אלו, הצלחנו להגיע לאחוזי הצלחה של כ-87 אחוזים כאשר $L=7$, וכ-91 אחוזים כאשר $L=10$.
 - תנאים שלא התקבלו:
 - פרדיקט הסוכם את כלל הפיקסלים ומשווה את הסכום המתקבל לערך מסוים. על תנאי זה ויתרנו מכיוון שלא ניכר שיפור ביכולות הזיהוי של האלגוריתם. נוסף על כך - זמן ריצת האלגוריתם הואט בצורה משמעותית.
 - פרדיקטים שונים שהתבססו על חישובי סכומים וממוצעים של פיקסלים ממאגר התמונות הנתון לנו לצורך הפרויקט. על פרדיקטים אלו ויתרנו כדי לא לפגוע בעיקרון הגנריות של פרדיקטים, אותו התבקשנו ליישם.
 - קבוצות פרדיקטים שקיבלנו בעזרת שימוש בפונקציית העזר "sumCube", בגדלים שונים מאלו שצינו לעיל. על פרדיקטים אלו ויתרנו מכיוון שהשיפור לו הם גרמו בדיוק התוצאות (במידה והיה שיפור), לא מפצה על פגיעתם בזמן הריצה.
2. אתגרים בהם נתקלנו במהלך המימוש:
 - אתגר הראשי איתו התמודדנו הוא צמצום זמן הריצה ל-60 שניות לכל היותר.
לאחר כתיבת הקוד, מעבר עליו ושיפור הפונקציות ככל הניתן, זמן הריצה אותו קיבלנו היה כ-65 שניות. במימוש זה, כל פרדיקט ביצע חישובים חוזרים (ומיותרים) עבור התמונות במהלך חישוב האנדרופיה בעלים, מה שגרם להאטת האלגוריתם. לאחר ניסיונות רבים, שכללו בין היתר שימוש במקביליות בקוד ורעיונות נוספים, לא הצלחנו לייעל את זמן הריצה באופן משמעותי. לבסוף הבנו שנוכל לחשב את הפרדיקטים על כל התמונות בזמן שאיבת המידע מקובץ ה csv ולהעביר הלאה מערך של אובייקטים ייחודיים - כאשר כל אובייקט מכיל מערך בוליאני בו שמורות תוצאות הפעלת הפרדיקטים על התמונות ובעצם ליצור מעין זיכרון cache נגיש. מהלך זה הביא לשיפור משמעותי בזמן הריצה של האלגוריתם - שיפור של כ-52 שניות מזמן הריצה של המימוש המקורי - כלומר זמן הריצה של האלגוריתם לאחר השינוי היה כ-13 שניות בלבד.

- אתגר נוסף איתו התמודדנו במהלך המימוש היה כיצד לייצג את הפרדיקט שנבחר לכל צומת בעץ ההחלטה שמייצר הקוד. המטרה היא שנוכל להעביר את העץ בין התוכניות (מ-learntree ל-predict). הניסיון להעברת המידע בעזרת json העלה בעיה - אובייקט מסוג פרדיקט איננו serializable - ולכן לא ניתן להעבירו בקלות. לכן יצרנו מעין storage שיחזיר את הפרדיקטים עבור כל גרסה - עבור שתי התוכניות, וכל פרדיקט יחזיק ב-id ייחודי שיאפשר לזהותו בצמתים של עצי ההחלטה וככה predict יבטיח ייצור עץ זהה לעץ שהתקבל באלגוריתם learntree. בקובץ ה-json העברנו את ה-id של הפרדיקט, עבור כל צומת, במקום את הפרדיקט עצמו – כך התוכנית predict תוכל לזהות את הפרדיקט המתאים לכל צומת. בנוסף, הוספנו אלמנט בקובץ ה json בשם "version", המייצג את הגרסה של מאגר הפרדיקטים איתה יש לעבוד, וכל פרדיקט המתאים לצומת בעץ ייוצג על ידי ה-id שלו במאגר.
- אתגר בחירת הפרדיקטים - לבחור את הפרדיקטים המתאימים ביותר. עם האתגר הזה התמודדנו באמצעות ניסיון לייצר קבוצות פרדיקטים מגוונות ששלימו אחת את השנייה בעזרת שיטות מיון שונות ובעזרת בדיקה האם תרומת קבוצת הפרדיקטים בשיפור התוצאות מפצה על הפגיעה בזמן הריצה.

3.

a.



- b. נשים לב, כי הגרסה השנייה של האלגוריתם הינה בעלת אחוז שגיאה נמוך יותר (כלומר - מדויקת יותר מהגרסה הראשונה) עבור כל גדלי המדגמים. שתי הגרסאות מתכנסות, כלומר - מגיעות לאחוזי שגיאה יחסית קבועים, החל ממדגם שגודלו כ-15 אלף תמונות ומעלה.
- c. השיפור באחוזי השגיאה בין שתי הגרסאות נובע מכך שהגרסה השנייה נבנתה במטרה לשפר את האלגוריתם – היא מכילה יותר פרדיקטים, הבודקים מגוון רחב יותר של תכונות שעשויות להיות לתמונות. שני האלגוריתמים מתכנסים לשגיאה (יחסית) קבועה - החל מגודל מדגם מסוים - מכיוון שגודל העץ המקסימלי בפרמטרים הנוכחיים מכיל את הפרדיקטים היעילים ביותר בכל צומת. הגדלת גודל המדגם לא משנה באופן ניכר את מבנה העץ.

.d

גרסה 1

		Prediction										
		0	1	2	3	4	5	6	7	8	9	
0	884	0	14	16	12	6	8	12	13	15	90.3% / 9.8%	Value
	90.2%	0.0%	1.4%	1.7%	0.8%	0.6%	0.8%	1.2%	1.3%	1.6%	884 / 980	
1	3	1076	12	15	1	3	9	5	11	0	94.8% / 5.2%	
	0.3%	94.8%	1.0%	1.3%	0.1%	0.3%	0.8%	0.4%	1.0%	0.0%	1076 / 1135	
2	41	33	657	25	38	13	45	34	112	34	63.6% / 36.4%	
	4%	3.2%	63.6%	2.4%	3.7%	1.2%	4.4%	3.3%	10.9%	3.3%	657 / 1032	
3	16	8	24	797	5	40	8	17	56	39	78.9% / 21.1%	
	1.6%	0.8%	2.4%	78.9%	0.5%	3.9%	0.8%	1.7%	5.5%	3.9%	797 / 1010	
4	8	11	21	8	736	8	27	12	41	110	74.9% / 25.1%	
	0.8%	1.1%	2.1%	0.8%	74.9%	0.8%	2.7%	1.2%	4.3%	11.3%	736 / 982	
5	40	7	25	181	17	527	24	10	37	24	59.0% / 41.0%	
	4.5%	0.8%	2.8%	20.3%	1.9%	59.0%	2.7%	1.1%	4.2%	2.7%	527 / 892	
6	43	4	17	18	41	12	776	8	38	1	81.0% / 19.0%	
	4.6%	0.4%	1.7%	1.8%	4.4%	1.2%	81.0%	0.8%	4.0%	0.1%	776 / 958	
7	3	6	54	4	21	4	0	852	18	66	82.6% / 17.2%	
	0.3%	0.6%	5.2%	0.4%	2.1%	0.4%	0.0%	82.6%	1.8%	6.4%	852 / 1028	
8	10	22	45	52	36	22	44	8	707	28	72.5% / 27.5%	
	1.0%	2.2%	4.7%	5.4%	3.7%	2.2%	4.6%	0.8%	72.5%	2.9%	707 / 974	
9	6	8	12	41	74	5	12	25	37	789	78.2% / 21.8%	
	0.6%	0.8%	1.2%	4.0%	7.3%	0.5%	1.2%	2.5%	3.7%	78.2%	789 / 1009	

גרסה 2





		Prediction										
		0	1	2	3	4	5	6	7	8	9	
0	927	6	9	7	9	2	10	3	4	3	94.7% / 5.3%	Value
	94.7%	0.6%	0.9%	0.7%	0.9%	0.2%	1.0%	0.3%	0.4%	0.3%	927 / 980	
1	0	1083	8	5	11	11	2	7	5	3	95.4% / 4.6%	
	0.0%	95.4%	0.7%	0.4%	1.0%	1.0%	0.2%	0.6%	0.4%	0.3%	1083 / 1135	
2	4	4	935	18	20	3	14	12	19	3	90.7% / 9.3%	
	0.4%	0.4%	90.7%	1.7%	1.9%	0.3%	1.3%	1.2%	1.8%	0.3%	935 / 1032	
3	4	6	46	833	8	59	0	20	23	11	82.5% / 17.5%	
	0.4%	0.6%	4.5%	82.5%	0.8%	5.8%	0.0%	2.0%	2.3%	1.1%	833 / 1010	
4	14	6	11	2	857	3	12	2	22	53	87.3% / 12.7%	
	1.4%	0.6%	1.1%	0.2%	87.3%	0.3%	1.2%	0.2%	2.3%	5.4%	857 / 982	
5	22	9	8	51	20	739	19	1	15	8	82.9% / 17.1%	
	2.2%	0.9%	0.9%	5.7%	2.2%	82.9%	2.2%	0.1%	1.7%	0.9%	739 / 892	
6	15	4	28	2	24	13	866	0	6	0	90.4% / 9.6%	
	1.6%	0.4%	2.9%	0.2%	2.5%	1.4%	90.4%	0.0%	0.6%	0.0%	866 / 958	
7	4	5	35	11	11	16	0	910	7	29	88.5% / 11.5%	
	0.4%	0.5%	3.3%	1.1%	1.1%	1.5%	0.0%	88.5%	0.7%	2.8%	910 / 1028	
8	20	13	32	17	29	45	8	3	777	30	79.8% / 20.2%	
	2.0%	1.3%	3.3%	1.7%	3.1%	4.6%	0.8%	0.3%	77.7%	3.1%	777 / 974	
9	21	9	4	22	44	37	0	13	10	849	84.2% / 15.8%	
	2.1%	0.9%	0.4%	2.2%	4.2%	3.7%	0.0%	1.3%	1.0%	84.2%	849 / 1009	

בגרסה הראשונה של האלגוריתם, הבדיקה שהעלתה את מספר הטעויות הרב ביותר הייתה כאשר כ-20% מהתמונות של הספרה 5 פוענחו כתמונות של הספרה 3, כ-10.8% מהתמונות של הספרה 2 פוענחו כתמונות של הספרה 8 וכ-11% מהתמונות של הספרה 4 פוענחו כתמונות של הספרה 9.

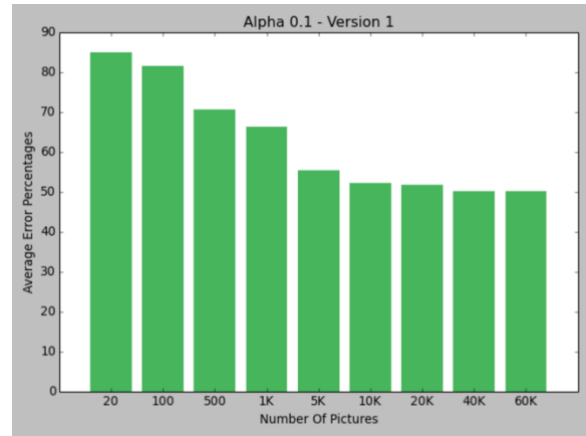

בגרסה השנייה של האלגוריתם, הבדיקה שהעלתה את מספר הטעויות הרב ביותר הייתה כאשר כ-5.8% מהתמונות של הספרה 3 פוענחו כתמונות של הספרה 5, כ-5.7% מהתמונות של הספרה 5 פוענחו כתמונות של הספרה 3 וכ-5.3% מהתמונות של הספרה 4 פוענחו כתמונות של הספרה 9.

ניתן לראות שהטעות הנפוצה ביותר, בהרצת שני האלגוריתמים, הייתה בזיהוי הספרה 3 כספרה 5 ולהפך. טעות זו נובעת ככל הנראה מנקודות הדמיון הרבות בין צורותיהן של שתי הספרות האלו. כגון: מספר "שינוי המגמה" בהסתכלות אנכית (מספר הפעמים בהם ערך של פיקסל באותו טור משתנה מאפס לערך חיובי, או להפך), צורה מעגלית בחצי תחתון וקווים אנכיים ואופקיים הנמצאים בטווח שורות דומה. גם בשאר המקרים בהן ספרה מסוימת פוענחה על ידי אחד מהאלגוריתמים כספרה אחרת, ניתן לראות בקלות נקודות חפיפה רבות בין הצורות של הספרות שהוחלפו.

כדי להמחיש דמיון זה, נציג את ממצע הפיקסלים עבור הספרות הנ"ל במדגם האימון:



4. (הערה: עבור כל ערך של α נענה על כל שלושת הסעיפים יחדיו)

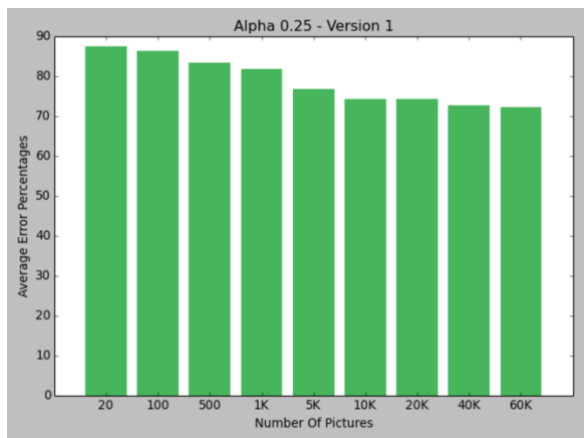



	Prediction									
	0	1	2	3	4	5	6	7	8	9
0	800 81.6%	7 0.7%	38 3.9%	36 3.7%	5 0.5%	26 2.7%	12 1.2%	18 1.8%	26 2.7%	12 1.2%
1	4 0.3%	856 75.4%	61 5.5%	21 1.8%	11 1.0%	25 2.2%	41 3.6%	39 3.4%	63 5.6%	14 1.2%
2	42 4.1%	58 5.6%	670 64.9%	42 4.1%	10 1.0%	20 1.9%	49 4.7%	55 5.3%	72 7.0%	14 1.4%
3	27 2.7%	47 4.6%	110 10.9%	491 48.6%	10 1.0%	82 8.2%	26 2.5%	61 6.1%	112 11.1%	44 4.3%
4	11 1.1%	21 2.1%	34 3.5%	32 3.3%	593 60.4%	25 2.5%	71 7.3%	15 1.5%	19 1.9%	161 16.4%
5	72 8.1%	46 5.1%	25 2.8%	166 18.7%	18 2.0%	352 39.5%	47 5.2%	41 4.6%	83 9.3%	42 4.7%
6	65 6.8%	28 2.9%	80 8.3%	24 2.6%	48 5.0%	45 4.7%	618 64.5%	10 1.0%	28 2.9%	12 1.3%
7	35 3.4%	45 4.4%	97 9.5%	23 2.2%	12 1.1%	24 2.3%	7 0.7%	605 58.9%	68 6.6%	112 10.9%
8	11 1.1%	51 5.2%	66 6.8%	70 7.2%	12 1.2%	29 3.0%	40 4.1%	13 1.3%	587 60.3%	95 9.8%
9	18 1.8%	13 1.3%	27 2.7%	59 5.8%	18 1.8%	34 3.4%	21 2.1%	48 4.7%	57 5.6%	714 70.8%

	Prediction									
	0	1	2	3	4	5	6	7	8	9
0	653 66.6%	6 0.6%	56 5.7%	34 3.5%	10 1.1%	53 5.4%	52 5.3%	94 9.6%	11 1.1%	11 1.1%
1	13 1.1%	843 74.2%	54 4.8%	74 6.5%	6 0.5%	10 0.9%	35 3.1%	31 2.7%	44 4.0%	25 2.2%
2	62 6.0%	93 9.0%	428 41.5%	60 5.8%	27 2.6%	31 3.0%	134 13.0%	75 7.3%	77 7.5%	45 4.3%
3	58 5.7%	77 7.6%	34 3.4%	518 51.2%	16 1.7%	91 9.0%	14 1.5%	65 6.4%	46 4.5%	91 9.0%
4	28 2.8%	52 5.3%	37 3.8%	48 4.9%	434 44.2%	23 2.3%	48 4.9%	119 12.1%	24 2.4%	169 17.3%
5	58 6.5%	40 4.5%	26 2.9%	185 20.8%	53 5.9%	267 29.9%	51 5.7%	85 9.6%	48 5.4%	79 8.8%
6	69 7.2%	30 3.1%	83 8.7%	35 3.6%	59 6.2%	21 2.2%	503 52.5%	75 7.8%	51 5.4%	32 3.3%
7	30 2.9%	37 3.5%	67 6.4%	32 3.1%	32 3.1%	84 8.2%	26 2.5%	619 60.1%	9 0.9%	97 9.5%
8	43 4.4%	98 10.1%	97 10.0%	84 8.7%	51 5.2%	31 3.2%	110 11.3%	45 4.6%	356 36.5%	59 6.0%
9	27 2.7%	50 4.9%	43 4.3%	74 7.3%	114 11.3%	29 2.9%	35 3.5%	152 15.0%	35 3.5%	450 44.6%

$\alpha = 0.1$

ניתן לראות כי גם הסתברות רעש קטנה פוגעת באחוזי ההצלחה בצורה ניכרת, אם כי עדיין יש שיפור קבוע עד להתכנסות. אחוזי ההצלחה של גרסת האלגוריתם השנייה טובים משל הגרסה הראשונה מכיוון שהפרדיקטים של הגרסה השנייה מסתכלים תמיד על קבוצת פיקסלים לעומת פיקסל בודד, מה שגורם לרעש להשפיע בצורה פחותה.





	Prediction									
	0	1	2	3	4	5	6	7	8	9
0	574 58.6%	24 2.5%	56 5.7%	94 9.6%	14 1.4%	21 2.1%	48 4.9%	27 2.8%	101 10.3%	21 2.1%
1	4 0.3%	568 50.0%	93 8.2%	33 2.9%	34 3.0%	39 3.4%	48 4.2%	72 6.4%	155 13.7%	89 7.9%
2	46 4.4%	107 10.3%	363 35.2%	32 3.1%	23 2.2%	19 1.8%	128 12.5%	38 3.7%	237 23.0%	39 3.8%
3	120 11.9%	73 7.2%	69 6.8%	307 30.4%	8 0.8%	38 3.8%	60 5.9%	27 2.7%	223 22.1%	85 8.4%
4	12 1.2%	63 6.4%	94 9.6%	55 5.6%	217 22.1%	6 0.6%	98 10.0%	47 4.8%	76 7.7%	314 32.0%
5	128 14.3%	71 8.0%	19 2.1%	173 19.4%	22 2.5%	76 8.5%	95 10.6%	40 4.5%	187 21.0%	81 9.1%
6	62 6.5%	44 4.6%	81 8.5%	31 3.2%	73 7.6%	28 2.9%	452 47.2%	15 1.5%	103 10.8%	69 7.2%
7	81 7.9%	101 9.9%	118 11.6%	93 9.0%	23 2.2%	6 0.6%	25 2.4%	273 26.5%	133 12.9%	175 17.0%
8	22 2.3%	49 5.0%	57 5.8%	52 5.3%	12 1.2%	13 1.3%	43 4.4%	33 3.4%	546 56.1%	147 15.2%
9	24 2.4%	24 2.4%	97 9.6%	91 9.0%	59 5.8%	7 0.7%	63 6.3%	74 7.3%	135 13.4%	435 43.1%

	Prediction									
	0	1	2	3	4	5	6	7	8	9
0	459 46.8%	71 7.2%	72 7.3%	48 4.9%	53 5.4%	35 3.6%	45 4.6%	158 16.2%	23 2.4%	16 1.6%
1	49 4.4%	642 56.6%	45 3.9%	76 6.7%	46 4.0%	29 2.5%	45 4.0%	100 8.8%	86 7.6%	17 1.5%
2	113 11.0%	202 19.7%	191 18.6%	66 6.4%	102 9.7%	21 2.0%	112 10.9%	132 12.9%	80 7.5%	13 1.3%
3	134 13.4%	191 18.9%	36 3.5%	291 28.8%	66 6.5%	49 4.8%	38 3.8%	122 12.2%	49 4.8%	34 3.3%
4	65 6.7%	121 12.3%	69 7.0%	47 4.8%	261 26.6%	30 3.0%	80 8.1%	212 21.6%	40 4.1%	57 5.8%
5	135 15.1%	122 13.7%	62 6.9%	156 17.5%	71 8.0%	77 8.7%	68 7.6%	134 15.0%	33 3.7%	34 3.8%
6	107 11.1%	140 14.6%	114 11.9%	51 5.3%	99 10.3%	24 2.5%	199 20.8%	139 14.5%	62 6.6%	23 2.4%
7	119 11.6%	131 12.7%	60 5.8%	37 3.6%	128 12.4%	21 2.1%	67 2.6%	411 40.0%	30 2.9%	24 2.3%
8	59 6.0%	237 24.3%	85 8.7%	128 13.1%	70 7.2%	31 3.2%	109 11.2%	90 9.3%	149 15.4%	16 1.6%
9	54 5.3%	126 12.5%	48 4.8%	101 10.0%	216 21.5%	47 4.6%	69 6.8%	215 21.3%	42 4.2%	91 9.0%

$$\alpha = 0.25$$

בדומה למקרה בו $\alpha = 0.1$ גם במקרה זה אחוזי השגיאה בכל גדלי המדגם גבוהים ואף גבוהים יותר - מכיוון שכ-25% מהפיקסלים התהפכו, מה שגרם לתמונות לאבד אף יותר את המכנה המשותף לצורתן.





	Prediction									
	0	1	2	3	4	5	6	7	8	9
0	589 60.1%	100 10.2%	62 6.3%	27 2.8%	41 4.2%	27 2.8%	29 3.0%	64 6.5%	20 2.0%	21 2.1%
										60.1% / 39.9% 589 / 980
1	400 35.2%	407 35.9%	9 0.8%	32 2.8%	34 3.0%	27 2.4%	76 6.7%	77 6.8%	24 2.1%	49 4.3%
										35.9% / 64.1% 407 / 1135
2	420 40.7%	182 17.6%	162 15.7%	35 3.4%	60 5.8%	22 2.1%	59 5.8%	31 3.0%	19 1.8%	42 4.1%
										15.7% / 84.3% 162 / 1032
3	445 44.1%	165 16.3%	43 4.2%	32 3.2%	43 4.3%	28 2.8%	60 5.9%	74 7.3%	28 2.8%	92 9.1%
										3.2% / 96.8% 32 / 1010
4	439 44.7%	143 14.6%	26 2.6%	13 1.3%	135 13.8%	18 1.9%	69 7.0%	57 5.8%	15 1.5%	67 6.8%
										13.8% / 86.2% 135 / 982
5	439 49.2%	158 17.7%	17 1.9%	23 2.6%	30 3.4%	39 4.4%	50 5.6%	74 8.3%	30 3.4%	32 3.5%
										4.4% / 95.6% 39 / 892
6	465 48.5%	109 11.4%	62 6.5%	17 1.8%	62 6.5%	35 3.7%	81 8.4%	57 5.9%	39 4.1%	31 3.2%
										8.4% / 91.6% 81 / 958
7	414 40.3%	206 20.0%	13 1.3%	22 2.1%	37 3.6%	15 1.5%	38 3.7%	167 16.2%	30 2.9%	86 8.4%
										16.2% / 83.8% 167 / 1028
8	462 47.4%	179 18.4%	9 0.9%	18 1.8%	31 3.2%	24 2.5%	37 3.8%	67 6.9%	87 8.9%	60 6.2%
										8.9% / 91.1% 87 / 974
9	438 43.4%	163 16.1%	18 1.8%	17 1.7%	72 7.1%	21 2.1%	53 5.3%	78 7.7%	27 2.7%	122 12.1%
										12.1% / 87.8% 122 / 1009

$$\alpha = 0.5$$

	Prediction									
	0	1	2	3	4	5	6	7	8	9
0	0 0.0%	597 60.9%	141 14.4%	0 0.0%	0 0.0%	0 0.0%	118 12.0%	124 12.7%	0 0.0%	0 0.0%
										0.0% / 100% 0 / 980
1	0 0.0%	710 62.6%	133 11.7%	0 0.0%	0 0.0%	0 0.0%	148 13.0%	144 12.7%	0 0.0%	0 0.0%
										62.6% / 37.4% 710 / 1135
2	0 0.0%	620 60.0%	146 14.1%	0 0.0%	0 0.0%	0 0.0%	139 13.5%	127 12.4%	0 0.0%	0 0.0%
										14.1% / 100% 146 / 1032
3	0 0.0%	625 61.9%	123 12.2%	0 0.0%	0 0.0%	0 0.0%	129 12.8%	133 13.1%	0 0.0%	0 0.0%
										0.0% / 100% 0 / 1010
4	0 0.0%	626 63.8%	122 12.4%	0 0.0%	0 0.0%	0 0.0%	121 12.3%	113 11.5%	0 0.0%	0 0.0%
										0.0% / 100% 0 / 982
5	0 0.0%	578 64.8%	105 11.8%	0 0.0%	0 0.0%	0 0.0%	102 11.4%	107 12.0%	0 0.0%	0 0.0%
										0.0% / 100% 0 / 892
6	0 0.0%	604 63.0%	100 10.4%	0 0.0%	0 0.0%	0 0.0%	133 13.9%	121 12.7%	0 0.0%	0 0.0%
										13.9% / 86.1% 133 / 958
7	0 0.0%	659 64.1%	129 12.6%	0 0.0%	0 0.0%	0 0.0%	115 11.2%	125 12.1%	0 0.0%	0 0.0%
										12.1% / 87.9% 125 / 1028
8	0 0.0%	611 62.7%	124 12.7%	0 0.0%	0 0.0%	0 0.0%	125 12.8%	114 11.8%	0 0.0%	0 0.0%
										0.0% / 100% 0 / 974
9	0 0.0%	628 62.2%	135 13.4%	0 0.0%	0 0.0%	0 0.0%	130 12.9%	116 11.5%	0 0.0%	0 0.0%
										0.0% / 100% 0 / 1009

ניתן לראות שבשתי הגרסאות הרעש מוביל לאחוזי הצלחה נמוכים מאוד המתאימים לאחוזי הצלחה של ניחוש מוחלט (באופן אקראי לחלוטין), זאת מכיוון שכאשר הופכים את ערכם של כ-50% מהפיקסלים התמונות הופכות ללא עקביות ובלתי ניתנות לזיהוי לקבוצות הפרדיקטים של שתי הגרסאות.











	Prediction									
	0	1	2	3	4	5	6	7	8	9
0	620 63.3%	1 0.1%	17 1.7%	4 0.4%	2 0.2%	157 16.0%	129 13.2%	48 4.9%	0 0.0%	2 0.2%
1	2 0.2%	858 75.6%	16 1.4%	20 1.7%	0 0.0%	181 15.9%	8 0.7%	4 0.4%	42 3.7%	4 0.4%
2	43 4.2%	79 7.7%	331 32.1%	26 2.5%	72 7.0%	167 16.2%	78 7.5%	114 11.0%	86 8.3%	36 3.5%
3	16 1.6%	44 4.4%	14 1.4%	490 48.5%	10 1.0%	230 22.8%	2 0.2%	39 3.8%	77 7.6%	88 8.7%
4	11 1.1%	27 2.7%	42 4.3%	21 2.1%	300 30.6%	144 14.7%	21 2.1%	132 13.5%	53 5.4%	231 23.5%
5	13 1.5%	13 1.5%	29 3.3%	66 7.4%	8 0.9%	653 73.2%	14 1.5%	2 0.2%	52 5.8%	42 4.7%
6	55 5.7%	13 1.4%	73 7.6%	10 1.0%	10 1.0%	198 20.8%	528 55.1%	4 0.4%	45 4.7%	22 2.3%
7	0 0.0%	28 2.7%	17 1.7%	15 1.5%	88 8.6%	190 18.5%	2 0.2%	543 52.8%	19 1.8%	126 12.2%
8	14 1.4%	79 8.1%	32 3.3%	141 14.5%	38 3.9%	129 13.2%	77 7.9%	21 2.2%	391 40.2%	52 5.3%
9	3 0.3%	27 2.7%	11 1.1%	19 1.9%	190 18.8%	159 15.8%	4 0.4%	129 12.8%	37 3.6%	430 42.6%



	Prediction									
	0	1	2	3	4	5	6	7	8	9
0	876 89.4%	0 0.0%	17 1.7%	21 2.2%	13 1.3%	6 0.6%	7 0.7%	12 1.3%	15 1.5%	13 1.3%
1	3 0.3%	1071 94.4%	6 0.5%	16 1.4%	1 0.1%	2 0.2%	17 1.5%	6 0.5%	13 1.1%	0 0.0%
2	31 3.0%	18 1.7%	710 68.8%	33 3.2%	27 2.6%	11 1.1%	42 4.1%	35 3.4%	98 9.5%	27 2.6%
3	7 0.7%	5 0.5%	32 3.2%	802 79.4%	5 0.5%	50 5.0%	9 0.9%	23 2.3%	43 4.2%	34 3.3%
4	9 0.9%	14 1.4%	22 2.2%	8 0.8%	734 74.8%	7 0.7%	30 3.1%	13 1.3%	38 3.9%	107 10.9%
5	36 4.1%	8 0.9%	29 3.3%	168 18.8%	17 1.9%	542 60.8%	18 2.0%	10 1.1%	36 4.0%	28 3.1%
6	41 4.2%	5 0.5%	21 2.2%	17 1.8%	42 4.4%	18 1.9%	772 80.6%	8 0.8%	34 3.5%	0 0.0%
7	2 0.2%	10 1.0%	49 4.8%	5 0.5%	20 1.9%	6 0.6%	2 0.2%	868 84.4%	2 0.2%	64 6.2%
8	11 1.1%	30 3.1%	53 5.4%	58 6.0%	31 3.2%	22 2.3%	44 4.5%	8 0.8%	688 70.6%	29 3.0%
9	5 0.5%	6 0.6%	16 1.6%	41 4.1%	70 6.9%	13 1.3%	12 1.2%	25 2.5%	37 3.6%	784 77.7%

$$\alpha = 1.0$$

ניתן לראות כי במקרה זה, בו כל הפיקסלים בכל התמונות התהפכו, אחוזי ההצלחה בגרסה הראשונה של האלגוריתם זהים לאחוזי ההצלחה בהרצה ללא רעש, ואילו אחוזי ההצלחה בגרסה השנייה של האלגוריתם נפגעו משמעותית (אם כי הם עדיין מראים מגמת התכנסות).

הסיבה להבדל זה היא שהתנאים בגרסה הראשונה משווים כל פיקסל לערך האמצע הפוטנציאלי שלו (128). לכן לכל פרדיקט, קבוצת התמונות שעבורן יוחזר הערך "true" וקבוצת התמונות עבורן יוחזר הערך "false" יתחלפו, אך אחוז ההצלחה יהיה זהה. לעומת זאת, קבוצת הפרדיקטים בגרסה השנייה מבוססת על השוואה לערך אידיאלי שאינו ערך האמצע (למשל, בחישוב ריבוע של 3x3 ערך האמצע יהיה 1152, אך אנו מצאנו שהערך הטוב ביותר להשוואה הינו 300) ולכן אחוזי ההצלחה נמוכים יותר מהרצה ללא רעש ואף מאחוזי ההצלחה של הגרסה הראשונה.





- b. מהגרפים ניתן להבחין כי ברוב המקרים ישנה עליה הדרגתית לעבר הגודל המקסימלי האפשרי של עץ ההחלטות. כאשר אין רעש גודל העץ גדל בצורה הדרגתית, וכשיש רעש השנוי בגודל העץ קיצוני יותר.
- c. כשאין רעש ככל שגודל המדגם גדול יותר, הגדלה של מספר הצמתים בעץ תיצור עץ החלטות שנייב שגיאה קטנה יותר, מכיוון שנבחרים פרדיקטים המשפרים את האנטרופיה של העץ. כאשר יש רעש בחירת פרדיקטים נוספים לא בהכרח מגדילה את יעילות העץ ולכן התנודה בגדלי העץ קיצונית יותר.